

Processamento de Big Data

Análise de Padrões de Seca nos EUA - Projeto de Aprendizagem
Não-Supervisionada

TRABALHO REALIZADO POR:

DANIEL FONSECA | 125158 | CD-PL-B1

DANIIL SAMSONYUK | 130646 | CD-PL-B1

GUILHERME PIRES | 131658 | CD-PL-B1

JOÃO FILIPE | 130665 | CD-PL-B1

DOCENTES:

GABRIELA SOARES

ALEXANDRE ALMEIDA

Índice

Introdução aos Dados	2
Estrutura e Variáveis do Dataset	2
Principais Resultados da Análise Exploratória	3
Nível nacional e temporal	3
A nível dos estados	3
Correlação área vs. população	4
Problemas Identificados e Limpeza de Dados	4
Questões de Investigação	5
Métodos Analíticos Realizados	5
Número de clusters	5
Avaliação da estabilidade	9
Caracterização dos três clusters	10
Resposta às questões de investigação	11
Conclusão	12
Declaração da Utilização de Ferramentas de IA	12
Referências	12

Introdução aos Dados

O *dataset* origina do “U.S. Drought Monitor” e regista semana a semana - ao longo de 20 anos (julho de 2001 a julho de 2021) - a intensidade de secas em todos os estados dos EUA.

O ficheiro principal (*drought.csv*) está em formato "longo" (*long format*): cada linha corresponde a um par estado/semana/nível de seca, com 10 variáveis, e respetivo valor de seca, nas categorias None, D0, D1, D2, D3 e D4. O *dataset* contém 325 728 linhas.

Os restantes 4 ficheiros (*drought_area_pct.csv*, *drought_area_total.csv*, *drought_pop_pct.csv*, *drought_pop_total.csv*) estão em formato "largo" (*wide format*): cada linha é um estado numa semana, e as colunas D0 a D4 representam os diferentes níveis de seca. Como cada ficheiro representa uma métrica, verificou-se que contêm a mesma informação do *dataset* principal em formato transposto, pelo que toda a análise foi conduzida exclusivamente pelo *drought.csv*.

Estrutura e Variáveis do Dataset

O *dataset* apresenta formato longo: cada combinação (data, estado) aparece 6 vezes, uma por cada nível de seca (None a D4). As variáveis presentes são, então, as seguintes:

Variável	Tipo	Descrição
<i>map_date</i>	Data	Identificador de data de publicação do mapa semanal
<i>state_abb</i>	Categórica	Abreviatura do estado/território
<i>drought_lvl</i>	Categórica	Nível de seca: None, D0, D1, D2, D3, D4. Sendo D4 o pior nível
<i>area_pct</i>	Numérica	% da área do estado nesse nível de seca
<i>area_total</i>	Numérica	Área total (milhas²) nesse nível de seca
<i>pop_pct</i>	Numérica	% da população do estado nesse nível de seca
<i>pop_total</i>	Numérica	Total de população nesse nível de seca
<i>stat_fmt</i>	Numérica	Formato estatístico (sempre = 2 neste dataset)
<i>valid_start / valid_end</i>	Data	Intervalo de validade semanal dos dados

Tabela 1: Análise das variáveis

As variáveis **stat_fmt**, **valid_start** e **valid_end** foram removidas por não acrescentarem valor: *stat_fmt* é constante (=2) e as datas de início/fim são derivadas de *map_date*.

Principais Resultados da Análise Exploratória

A análise exploratória foi realizada em três níveis: nacional, estadual e temporal.

Nível nacional e temporal

A análise da média nacional de área em seca revela padrões cíclicos anuais, com dois períodos de seca particularmente severos: 2002–2004 e 2012. O ano de 2012 destaca-se como o **pico** do período analisado, o que coincide com a seca **mais grave** registada nos EUA nas últimas décadas.




Figura 1: Nível médio de severidade de seca ao longo dos anos (2001-2021)

A nível dos estados

Os estados mais afetados pela seca são, por ordem decrescente: **AZ, NV, NM, UT e CA**, todos no sudoeste. Por outro lado, os estados com menor exposição à seca são **OH, AK, WV e IN**.

Fez-se uma análise de tendências comparando a década de 2001–2011 com 2012–2021 o que revelou resultados surpreendentes: para além dos estados ocidentais esperados (CA, UT, OR), toda a região da **Nova Inglaterra** (VT, CT, MA, RI, NH, NY) apresenta uma deterioração significativa na segunda década, sugerindo uma alteração geográfica. Por outro lado, estados como **WY, MT e NC** registaram melhorias, com diminuição das secas.




Figura 2: Variação do nível de severidade de seca por Estado

Correlação área vs. população

A correlação de Pearson entre *area_pct* e *pop_pct* é superior a 0.86 em todos os níveis de seca.

Verificou-se também que para níveis severos (D2-D4), a *area_pct* é sistematicamente superior à *pop_pct*, indicando que a seca extrema afeta desproporcionalmente zonas rurais.

Problemas Identificados e Limpeza de Dados

A inspeção do *dataset* revelou os seguintes problemas, todos devidamente tratados:

Tipo de dados incorreto: A variável *map_date* estava codificada como inteiro (ex: 20210713). Foi convertida para *DateType* com o formato *yyyyMMdd*.

Valores fora do intervalo: A variável *pop_pct* apresentava 1489 linhas com valores superiores a 100%, concentradas maioritariamente no nível 'None' e em poucos estados (IA, GA, VA, SD, WA). A causa provável são erros de arredondamento, na soma dos 6 níveis de seca. Foi aplicado um *cap* a 100%.

Integridade: Verificou-se que todas as 54.288 combinações (*map_date*, *state_abb*) contém exatamente 6 linhas (uma por nível de seca), confirmando a integridade estrutural do *dataset*.

Verificámos que não existem valores nulos nem variáveis duplicadas no *dataset*.

Questões de Investigação

Com base na exploração dos dados, o grupo decidiu formular as seguintes questões:

1. Existem grupos de estados com perfis de seca semelhantes, considerando a distribuição ao longo dos níveis D0–D4?
2. O que explica a comunalidade de seca entre estados? É a sua proximidade geográfica ou é possível agrupar estados geograficamente distantes no mesmo grupo?
3. É possível identificar períodos temporais com padrões de seca distintos que correspondam a eventos históricos conhecidos?
4. Qual a evolução da seca nos EUA nos últimos 20 anos?
5. Será o nosso modelo valioso para possíveis investidores (ou entidades públicas) no setor da agricultura? Por exemplo, podemos aconselhar quais os melhores estados para investir neste setor dependendo do tipo de plantação?

Métodos Analíticos Realizados

Para responder às questões acima, o grupo utilizou o seguinte método:

K-Means Clustering: De forma a agrupar os estados em diferentes grupos com características semelhantes, realizou-se um *clustering* com *K-Means* com um número de clusters avaliado pelo método do cotovelo.

Optou-se por escolher a variável de *area_pct* devido a não enviesar o modelo com valores absolutos (*area_total* e *pop_total*). E entre *area_pct* e *pop_pct*, escolhemos *area_pct* porque queremos diferenciar os territórios afetados pela sua área, não pelas pessoas..

O **K-Means** é adequado pela sua interpretabilidade. Dado o objetivo de identificar perfis de seca, o reduzido número de observações (~52 estados), a ausência de *outliers* e o tipo das features (dados contínuos) ajudam este modelo a ser o preferido. As features foram normalizadas com *StandardScaler* antes da modelação.

Número de clusters

Para escolher o valor de K foram aplicados dois critérios: o método do cotovelo e o *Silhouette Score*. Foram testados valores de K entre 2 e 10 e com a categoria D0 incluída e excluída. Adiante, será aprofundado o porquê desta última alteração.

A Tabela 1 apresenta a comparação dos *Silhouette Scores* entre os dois cenários:

K	Silhouette com D0	Silhouette sem D0	Melhoria
2	0,7028	0,7751	+0,0723
3	0,6052	0,7361	+0,1309
4	0,6349	0,5414	-0,0935
5	0,4827	0,6569	+0,1742
6	0,5049	0,5941	+0,0892

Tabela 2: Comparação de Silhouette Scores com e sem D0.

Apesar do K=2 conferir os melhores resultados no Silhouette Score, nunca poderíamos seguir esta opção dado que criaria apenas 2 clusters tornando a interpretação binária - seca ou não seca - o que não cumpriria com o objetivo do presente trabalho.

Inicialmente, após observar a tabela 1 assim como o gráfico do Método do Cotovelo (Fig. 3) optámos por seguir a opção de K = 4 com a categoria D0 incluída.




Figura 3: Elbow Method com D0

Contudo, após uma análise ao radar chart (Fig.4 e Fig.8) detalhada, optámos pela redução para K = 3 por dois motivos fundamentais:

- **Interpretabilidade Substantiva:** Com K = 4, o modelo criava um grupo redundante que não oferecia uma distinção climática clara face aos restantes. Podemos observar que o Cluster 0 e o Cluster 3 não oferecem uma distinção clara, tendo praticamente os mesmos valores.

Ademais, todos os clusters apresentam os seus valores mais elevados, na categoria D0, à exceção do Cluster 1.

- **Métricas de Qualidade:** O Silhouette Score para K = 4 - com D0 vs K=3 sem D0 - revelou-se inferior, indicando que a criação de um quarto grupo estava a forçar a divisão de estados que partilhavam características climáticas muito semelhantes, gerando maior sobreposição entre clusters.




Figura 4: Análise dos *Clusters* com K=4 e D0

Clustering de Estados por Perfil de Seca (K=4)




Figura 5: Mapa dos *Clusters* com K=4

No mapa da Figura 5 podemos conferir que o Cluster 0 tem, de facto, dificuldades em agregar os estados.

Assim, experimentámos fazer um novo K-Means e excluir a categoria D0. A motivação para esta decisão deriva do facto de como todos os clusters apresentam valores altos nesta categoria, é uma comunabilidade entre clusters diferentes - o que dificulta a interpretação. Ademais, segundo o *website* da US Drought Monitor, a categoria D0 pode significar 2 coisas:

“(…) uses the D0 category to indicate abnormally dry areas that could be entering or recovering from drought.”: *US Drought Monitor*

<https://droughtmonitor.unl.edu/About/AbouttheData/DroughtClassification.aspx>

Ao contrário dos níveis D1–D4, que representam seca confirmada de intensidade crescente, o D0 não distingue entre deterioração e recuperação, introduzindo **ruído conceitual** no modelo.

A Tabela 1 demonstra que a remoção da categoria D0 melhora o *Silhouette Score* em quase todos os valores de K, com exceção de K = 4 e podemos ver que K = 3 (*Silhouette* = 0,7361) é a melhor solução.




Figura 6: *Elbow Method* sem D0

O gráfico do Método do Cotovelo (Fig. 6) apresentou uma resposta diferente: que K=4 sem D0 continuava a ser a melhor opção. No entanto, devido à justificação apresentada acima, assim como um *Silhouette Score* mais elevado, optámos por seguir com K = 3.

Clustering de Estados por Perfil de Seca: K=3 sem D0




Figura 7: Mapa dos *Clusters* com K=3

Através do mapa da Figura X, já conseguimos observar uma clara distinção e “linhas” que

separam os estados de acordo com o seu nível de seca, de uma forma mais lógica.




Figura 8: Análise dos *Clusters* com K=3 sem D0

Com estes novos resultados, podemos ver uma diferença clara entre os 3 clusters.

Avaliação da estabilidade

Foi conduzida uma análise de estabilidade testando 5 sementes aleatórias diferentes (42, 123, 456, 789, 1000) para K = 4 com D0 e para K = 3 sem D0. Esta validação permite avaliar se a solução é robusta ou dependente de uma inicialização particular.

K=4 com D0:

Seed	Silhouette Score
42	0.6349
123	0.6675
456	0.6460
789	0.6138
1000	0.4742

Tabela 3: *Silhouette Score* com K=4 e D0

K=3 sem D0:

Seed	Silhouette Score
42	0,7361
123	0,7361
456	0,7361
789	0,7361

1000	0,7361
------	--------

Tabela 4: *Silhouette Score* com K=3 sem D0

Seed	Cluster 0	Cluster 1	Cluster 2
42	[0.737, 0.747, 0.834, 0.618]	[-0.574, -0.604, -0.622, -0.539]	[1.992, 2.169, 2.063, 2.060]
123	[-0.574, -0.604, -0.622, -0.539]	[1.992, 2.169, 2.063, 2.060]	[0.737, 0.747, 0.834, 0.618]
456	[1.992, 2.169, 2.063, 2.060]	[-0.574, -0.604, -0.622, -0.539]	[0.737, 0.747, 0.834, 0.618]

Confirmamos, portanto, que o resultado de silhouette score é fidedigno, porque:

1. **Centróides idênticos:** os três centróides são os mesmos em todas as execuções.
2. **Label switching:** o **K-Means** não garante que o Cluster 0 de uma execução corresponda ao Cluster 0 de outra.

A análise de estabilidade com cinco sementes diferentes produziu centróides numericamente idênticos em todas as execuções (Silhouette = 0,7361 em todas), confirmando que o algoritmo converge consistentemente para a mesma solução ótima.

Caracterização dos três *clusters*

Os três clusters obtidos são apresentados na tabela 3, com centróides em escala original. Os valores representam a percentagem média de área estadual classificada em cada nível de seca, calculada como média das 1044 semanas do período analisado e agregada pelos estados de cada cluster, por exemplo:

O valor **D3 = 11,6** significa: "Em média, ao longo de 20 anos, 11,6% da área total de um estado do Cluster 2 estava classificada em seca extrema (D3) em qualquer semana."

Ou seja, num estado como o Arizona, numa semana aleatória entre 2001 e 2021, cerca de 11,6% do seu território estaria tipicamente em seca extrema:

Cluster	Designação	D1	D2	D3	D4	N estados
0	Seca Moderada (Planícies)	13,5	10,6	7,1	2,4	13
1	Baixa Seca (Este)	5,7	2,5	0,9	0,1	34
2	Seca Severa (Sudoeste)	20,4	18,3	11,6	4,1	5

Tabela 5: Centróides dos três clusters identificados (% de área média, D1–D4)

O **Cluster 0** - Seca Moderada é composto por 13 estados ocupa posição intermédia, reunindo estados das Grandes Planícies, Pacífico Noroeste e alguns do sul atlântico, com valores moderados em D1–D3. Os estados neste cluster formam uma faixa de transição entre o Este húmido e o árido Oeste.

O **Cluster 1** - Baixa Seca, o mais numeroso com 34 estados, agrupa os estados do Este e Nordeste, onde a precipitação é abundante e regular com seca essencialmente limitada a D1 (5,7%) e praticamente valores inexistentes em D3 e D4.

O **Cluster 2** - Seca Severa (5 estados) corresponde aos desertos sudoeste dos EUA, caracterizado por clima mediterrânico e desértico. Apresenta valores muito elevados em todos os níveis de seca, incluindo D3 (11,6%) e D4 (4,1%), indicando seca crónica e severa.

Acreditamos que o Cluster 2 está a crescer. CA, já no Cluster 2, foi o estado que mais agravou na segunda década (+5%). No entanto, se estados como OR e WA que estão atualmente no Cluster 0 continuarem a agravar, poderão eventualmente passar para o Cluster 2. O que hoje são 5 estados poderão ser 7 ou 8 em 2040

Resposta às questões de investigação

Q1 : Existem grupos de estados com perfis de seca semelhantes, considerando a distribuição ao longo dos níveis D0–D4?

R: O *K-Means*, com a seleção adequada de features (D1–D4) e $K=3$, identifica três grupos naturais de estados com perfis de seca claramente distintos, suportados por um *Silhouette Score* de 0,7361.

Q2 : O que explica a comunalidade de seca entre estados? É a sua proximidade geográfica ou é possível agrupar estados geograficamente distantes no mesmo grupo?

R: A maior parte dos agrupamentos é geograficamente coerente: o **Cluster 2** corresponde quase perfeitamente ao Sudoeste árido e o **Cluster 1** ao Este e Nordeste mais húmidos. No entanto, o **Cluster 0** revela a existência de estados parecidos não estando geograficamente perto. O algoritmo conseguiu representar a estrutura climática dos EUA, não lhe tendo sido fornecido qualquer tipo de informação geográfica.

Q3 : É possível identificar períodos temporais com padrões de seca distintos que correspondam a eventos históricos conhecidos?

R: Através da análise da Figura 1 foi possível identificar dois marcos históricos de seca nos EUA: o período de **2002-2004** e a **Seca de 2012**, que foi a seca mais severa desde a seca de 1956 e

também representa o pico máximo de severidade em todo o período analisado (2001-2021).

Q4 : Qual a evolução da seca nos EUA nos últimos 20 anos?

R: Nos últimos 20 anos a evolução da seca nos EUA caracteriza-se pela expansão para o Nordeste e pela severidade do Sudoeste. Enquanto a região da Nova Inglaterra (como MA, CT e NY) viu um agravamento inédito na última década, o **Cluster 2** do Sudoeste (CA, AZ, NV) consolidou-se como uma zona de seca severa permanente. Em sentido oposto, estados como Wyoming, Montana e Carolina do Norte registaram melhorias graduais no mesmo período.

Q5 : Será o nosso modelo valioso para possíveis investidores (ou entidades públicas) no setor da agricultura?

R: Os *clusters* oferecem a seguinte orientação estratégica: o **Cluster 2** desaconselha claramente culturas de elevada exigência hídrica, enquanto o **Cluster 1** oferece maior estabilidade. Dado que o K-Means representa médias, podemos ter estados - como mencionado anteriormente - que estão no Cluster 1 e que, daqui a alguns anos, podem estar no Cluster 2. Assim, o modelo revela-se mais valioso em dizer em que estados não investir do que investir.

Conclusão

O presente estudo permitiu transformar dados históricos do *U.S. Drought Monitor* em conhecimento geoespacial e climático estruturado. Através da implementação de uma pipeline de processamento em *PySpark*, foi possível superar o desafio de analisar 20 anos de registos semanais, o que revelou que a seca nos EUA não é um fenómeno uniforme.

Um resultado particularmente relevante foi o agravamento observado na Nova Inglaterra na segunda década do estudo. A análise de tendências mostrou os estados desta área com agravamento sistemático entre 2001-2011 e 2012-2021. Estes estados estão no Cluster 1 (Baixa Seca) mas as médias de 20 anos ocultam que na segunda década já se aproximam do perfil do Cluster 0. Se os dados continuassem até 2030, alguns destes estados poderiam mudar de cluster. Achamos que isto é um indicador de expansão geográfica da seca.

Do ponto de vista metodológico, a decisão de excluir o nível D0 foi determinante. Sem essa decisão, o modelo agrupava estados em 2 clusters de forma demasiado genérica. Assim, o Silhouette Score passou de 0,61 para 0,74 e os grupos obtidos tornaram-se geograficamente coerentes e interpretáveis.

Declaração da Utilização de Ferramentas de IA

Foi utilizado um assistente de IA (Claude, Anthropic) durante o desenvolvimento do trabalho, para as seguintes finalidades:

- Brainstorming com avaliação de estratégias
- Recomendações sobre tipos de gráficos (radar chart e mapa animado) adequados a cada situação
- Revisão linguística e aprimoração de linguagem técnica.

Referências

U.S. Drought Monitor (2021). National Drought Mitigation Center, University of Nebraska-Lincoln, USDA and NOAA. <https://droughtmonitor.unl.edu/>

Apache Spark MLlib Documentation - K-Means clustering
<https://spark.apache.org/docs/latest/ml-clustering.html>

Alexandre A. (2026). PBD-Aula-04. ISCTE-Instituto Universitário de Lisboa
https://moodle25.iscte-iul.pt/pluginfile.php/284551/mod_page/content/27/W04_ML_Pipeline_Presentation.pdf?time=1773226557553